

Laboratorio evolutivo 02

Resiliencia y escalabilidad de Digital Café Luna en AWS

Cloud Computing Posgrado · Semana 2 · Cuenta AWS estándar

Duración	Modalidad	Entorno	Carácter
90 minutos	Equipos de 4	Cuenta AWS estándar	Formativo; con evidencia

1. Propósito y resultado

Demostrar comportamiento observable ante distribución y fallo de cómputo, separando con precisión las responsabilidades de health, balanceo y recuperación de capacidad.

Al finalizar, el equipo tendrá un Application Load Balancer conectado a un Target Group y a un Auto Scaling Group distribuido en dos Availability Zones. Observará cómo el tráfico deja de ir a un target no elegible y cómo el ASG recupera desired capacity después de terminar deliberadamente una instancia.

Objetivos de aprendizaje

- Explicar qué observa un health check y por qué un target saludable no equivale a una instancia inmune a fallos.
- Demostrar que el ALB distribuye solicitudes únicamente hacia targets elegibles.
- Relacionar min, desired y max capacity con el comportamiento real del Auto Scaling Group.
- Observar una recuperación de capacidad sin atribuirla incorrectamente al health check del ALB.
- Registrar evidencia técnica suficiente para reconstruir la secuencia de fallo y recuperación.

Alcance de esta iteración

Incorporamos la conectividad mínima para exponer un ALB, dos instancias reproducibles y un ASG. La configuración de Internet Gateway, ruta y security groups se trata como prerequisite operativo, no como clase de networking. No usaremos NAT Gateway, NACL avanzadas, scaling policies, observabilidad profunda, persistencia ni IaC.

Ruta de trabajo

Tiempo	Bloque	Salida
0–10 min	Preflight + baseline S01	VPC y subnets verificadas
10–25 min	Conectividad mínima + SG	ALB y targets con flujo posible
25–45 min	Launch Template + Target Group	Cómputo reproducible y health definido
45–60 min	ALB + Auto Scaling Group	2 instancias distribuidas
60–70 min	Prueba A: distribución	Dos targets observados
70–82 min	Prueba B: terminación	Reemplazo y recuperación observados
82–90 min	Evidencia + cleanup + checkpoint	Baseline S01 restaurado

Arquitectura objetivo




Figura 1. S02 agrega balanceo y recuperación de cómputo sobre el baseline de S01.

La VPC y las dos subnets se heredan de S01. Para este lab ambas subnets reciben temporalmente una ruta 0.0.0.0/0 hacia un Internet Gateway: el ALB será internet-facing y las instancias necesitan salida breve a Internet para instalar el servidor HTTP desde user data. Las instancias tendrán public IPv4 temporal, pero el puerto 80 solo aceptará tráfico desde el security group del ALB.

2. Estándar del laboratorio

Región y baseline

Trabajen en us-east-1 (N. Virginia) para mantener consistencia entre equipos. Antes de crear recursos, validen el baseline exacto de S01 y no lo dupliquen.

Recurso	Nombre / valor
VPC	dcl-dev-vpc · 10.20.0.0/16
Subnet A	dcl-dev-subnet-a · 10.20.1.0/24
Subnet B	dcl-dev-subnet-b · 10.20.2.0/24
Distribución	Dos Availability Zones distintas

Nomenclatura S02

Recurso	Nombre
Internet Gateway	dcl-dev-igw-s02
Route table temporal	dcl-dev-rt-s02-public
Security group ALB	dcl-dev-sg-alb
Security group aplicación	dcl-dev-sg-app
Launch Template	dcl-dev-lt-web
Target Group	dcl-dev-tg-web
Application Load Balancer	dcl-dev-alb

Etiquetas

Apliquen `dcl:project=digital-cafe-luna`, `dcl:environment=dev`, `dcl:owner-team=team-XX` y `dcl:managed-by=console` donde el servicio permita etiquetar el recurso. El Name tag debe corresponder al recurso, no reutilizarse entre componentes.

3. Preflight técnico

Qué hacemos: Confirmar cuenta, Región, baseline y permisos normales de la cuenta.

Por qué: El lab necesita crear recursos EC2, Elastic Load Balancing, Auto Scaling y VPC. En cuentas AWS estándar no existe un gate específico de Academy, pero la identidad usada debe tener permisos suficientes.

- 1. Inicien sesión en la cuenta AWS y seleccionen us-east-1.
- 2. En VPC, confirmen dcl-dev-vpc y las dos subnets heredadas con sus CIDR exactos y AZ distintas.
- 3. Verifiquen que no exista ya un stack S02 activo con los mismos nombres. Reutilicen solo si coincide con esta guía y está en estado esperado.
- 4. Si una política IAM de la cuenta bloquea una operación, registren el error y escálenlo al administrador de la cuenta. No creen access keys como workaround.

Validación: La Región es us-east-1; VPC y subnets coinciden con S01; la identidad puede abrir EC2, Load Balancers, Target Groups y Auto Scaling Groups.

Paso 1 — Preparar conectividad mínima

Qué hacemos: Crear un Internet Gateway y una route table temporal para que el ALB sea internet-facing y las instancias puedan instalar el servidor HTTP.

Por qué: AWS requiere un Internet Gateway para seleccionar una VPC en un ALB internet-facing. Además, el user data necesita salida a Internet para instalar httpd. No usaremos NAT Gateway.

- 5. En VPC > Internet gateways, creen dcl-dev-igw-s02 y adjúntenlo a dcl-dev-vpc.
- 6. En Route tables, creen dcl-dev-rt-s02-public para dcl-dev-vpc.
- 7. Agreguen la ruta 0.0.0.0/0 con destino dcl-dev-igw-s02.
- 8. Asocien explícitamente dcl-dev-subnet-a y dcl-dev-subnet-b a esta route table.
- 9. No cambien el atributo general de auto-assign public IPv4 de las subnets; el Launch Template lo resolverá para sus instancias.

Validación: Ambas subnets muestran asociación con dcl-dev-rt-s02-public y la tabla contiene la ruta local 10.20.0.0/16 más 0.0.0.0/0 → Internet Gateway.

Paso 2 — Crear security groups mínimos

Qué hacemos: Separar el acceso al ALB del acceso a las instancias.

Por qué: El ALB debe recibir HTTP desde Internet, pero las instancias no deben aceptar HTTP directamente desde Internet.

Security group	Inbound	Outbound
dcl-dev-sg-alb	TCP 80 desde 0.0.0.0/0	Default
dcl-dev-sg-app	TCP 80 desde dcl-dev-sg-alb	Default

Validación: No existe regla SSH requerida. El SG de aplicación referencia al SG del ALB como origen del puerto 80.

4. Cómputo reproducible y health

Paso 3 — Crear el Launch Template

Qué hacemos: Definir cómo debe nacer cada instancia del ASG.

Por qué: La recuperación solo es útil si el reemplazo puede reconstruirse de forma consistente sin configuración manual.

10. En EC2 > Launch Templates, creen dcl-dev-lt-web.
11. AMI: Amazon Linux 2023, arquitectura x86_64, desde Quick Start.
12. Instance type: t3.micro. No configuren key pair ni acceso SSH para este lab.
13. Network interface: no fijen una subnet; habiliten Auto-assign public IP y asignen dcl-dev-sg-app.
14. Conserven el volumen root mínimo de la AMI y confirmen Delete on termination = Yes.
15. En User data, peguen el script siguiente.

```
#!/bin/bash
set -euxo pipefail
dnf install -y httpd

TOKEN=$(curl -sS -X PUT \
-H "X-aws-ec2-metadata-token-ttl-seconds: 21600" \
http://169.254.169.254/latest/api/token)

INSTANCE_ID=$(curl -sS \
-H "X-aws-ec2-metadata-token: $TOKEN" \
http://169.254.169.254/latest/meta-data/instance-id)

AZ=$(curl -sS \
-H "X-aws-ec2-metadata-token: $TOKEN" \
http://169.254.169.254/latest/meta-data/placement/availability-zone)

echo "Digital Café Luna | instance=${INSTANCE_ID} | az=${AZ}" \
> /var/www/html/index.html

systemctl enable --now httpd
```

Validación: El Launch Template existe, no fija subnet, asigna public IPv4 temporal, usa dcl-dev-sg-app y contiene user data reproducible.

Paso 4 — Crear el Target Group y health check

Qué hacemos: Definir el conjunto de destinos al que el ALB puede enviar tráfico y cómo decide si un target es elegible.

Por qué: El health check del Target Group responde a una pregunta concreta: ¿este target puede atender HTTP en este momento?

16. En EC2 > Target Groups, creen dcl-dev-tg-web.
17. Target type = Instances; Protocol = HTTP; Port = 80; VPC = dcl-dev-vpc.
18. Health check: HTTP, path /, success code 200. Para agilizar el lab pueden usar interval = 10 s y healthy threshold = 2.
19. No registren instancias manualmente; el Auto Scaling Group las registrará después.

Validación: El Target Group existe y no contiene targets todavía.

5. Balanceo y Auto Scaling

Paso 5 — Crear el Application Load Balancer

Qué hacemos: Exponer un único endpoint y distribuir tráfico hacia el Target Group.

Por qué: El cliente no necesita conocer las instancias. El ALB selecciona targets elegibles y deja de enviar nuevas solicitudes a targets que ya no lo sean.

20. En EC2 > Load Balancers, creen un Application Load Balancer llamado dcl-dev-alb.
21. Scheme = Internet-facing; IP address type = IPv4; VPC = dcl-dev-vpc.
22. Seleccionen dcl-dev-subnet-a y dcl-dev-subnet-b, cada una en su AZ.
23. Security group = dcl-dev-sg-alb.
24. Listener HTTP :80 → Forward to dcl-dev-tg-web.
25. Esperen a que State = Active y copien el DNS name.

Validación: dcl-dev-alb está Active, habilitado en dos AZ y su listener HTTP reenvía a dcl-dev-tg-web.

Paso 6 — Crear el Auto Scaling Group

Qué hacemos: Mantener dos instancias activas a partir del mismo Launch Template y distribuir las entre las dos subnets.

Por qué: desired capacity expresa la capacidad que el grupo intentará mantener. min y max son límites; max=4 no significa que el grupo escalará automáticamente hasta cuatro instancias.

26. En EC2 > Auto Scaling Groups, creen dcl-dev-asg-web usando dcl-dev-lt-web.
27. VPC = dcl-dev-vpc; subnets = dcl-dev-subnet-a y dcl-dev-subnet-b.
28. Attach to an existing load balancer target group = dcl-dev-tg-web.
29. Health check type: conserven EC2. No habiliten Elastic Load Balancing health checks en este lab.
30. Group size: Desired capacity = 2; Min desired capacity = 2; Max desired capacity = 4.
31. No creen scaling policy. El objetivo es observar recuperación de desired capacity, no elasticidad basada en demanda.
32. Agreguen Name=dcl-dev-web y etiquetas del proyecto con propagación a instancias cuando aplique.

Validación: El ASG muestra min=2 / desired=2 / max=4; aparecen dos instancias InService; el Target Group termina mostrando dos targets healthy.

OJO TÉCNICO: En este lab el Target Group usa health checks para decidir si el ALB debe enviar tráfico. El ASG conserva el health check type EC2; por tanto, un fallo del health check del ALB no se usa como señal de reemplazo del ASG. Esa separación es deliberada para observar la causalidad sin ambigüedad.

6. Prueba A — Distribución

Qué hacemos: Enviar múltiples solicitudes al endpoint del ALB y demostrar que las respuestas provienen de al menos dos instancias.

Por qué: El DNS del ALB representa un punto de entrada estable, mientras que las instancias detrás del Target Group son reemplazables.

33. Confirman en dcl-dev-tg-web que hay dos targets en estado healthy.
34. Copien el DNS name de dcl-dev-alb.
35. Desde un navegador, abran `http://<ALB_DNS>` para validar acceso básico.
36. Para obtener evidencia repetible, ejecuten varias solicitudes desde un terminal. El resultado debe contener al menos dos instance IDs; la distribución exacta no tiene que ser 50/50.

```
ALB_DNS=$(aws elbv2 describe-load-balancers \
--names dcl-dev-alb \
--query 'LoadBalancers[0].DNSName' \
--output text)
```

```
for i in {1..20}; do
  curl -s "http://${ALB_DNS}"
  echo
done | sort | uniq -c
```

Validación: La salida contiene respuestas de por lo menos dos instance IDs y, normalmente, de las dos AZ. Si solo aparece un ID, confirmen primero que ambos targets estén healthy y repitan la muestra.

Verificación técnica opcional por AWS CLI

```
TG_ARN=$(aws elbv2 describe-target-groups \
--names dcl-dev-tg-web \
--query 'TargetGroups[0].TargetGroupArn' \
--output text)
```

```
aws elbv2 describe-target-health \
--target-group-arn "$TG_ARN" \
--query 'TargetHealthDescriptions[].[Instance:Target.Id,State:TargetHealth.State]' \
--output table
```

```
aws autoscaling describe-auto-scaling-groups \
--auto-scaling-group-names dcl-dev-asg-web \
--query 'AutoScalingGroups[0].{Min:MinSize,Desired:DesiredCapacity,Max:MaxSize,Instances:Instances[0].InstanceId}' \
--output json
```

Si no tienen AWS CLI local configurado, pueden usar CloudShell o realizar la validación equivalente en consola. No creen access keys solo para ejecutar estos comandos.

Evidencia de la Prueba A

- Captura del ALB Active con su DNS name.
- Captura del Target Group con dos targets healthy.
- Salida de solicitudes mostrando al menos dos instance IDs.
- Captura del ASG con min=2 / desired=2 / max=4.

7. Prueba B — Terminación controlada

Qué hacemos: Terminar deliberadamente una instancia perteneciente al ASG y observar la recuperación.

Por qué: Queremos separar tres comportamientos: health decide elegibilidad, ALB decide a dónde enviar tráfico y ASG mantiene la capacidad deseada.

37. En EC2 > Instances, identifiquen las dos instancias cuyo Auto Scaling group es dcl-dev-asg-web y registren sus IDs.
38. Seleccionen una de ellas y ejecuten Instance state > Terminate instance. No reduzcan desired capacity del ASG.
39. Mantengan abiertas tres vistas: Target Group > Targets, Auto Scaling Group > Activity y EC2 > Instances.
40. Continúen haciendo solicitudes al ALB mientras observan el cambio. El servicio debe seguir respondiendo desde el target elegible restante.
41. Observen que la instancia terminada deja de ser elegible para nuevas solicitudes. Puede aparecer temporalmente como draining/unused mientras se completa la desregulación.
42. En Activity history, observen la actividad que lanza una instancia para recuperar la capacidad del grupo.
43. Espere a que la nueva instancia pase por Pending → InService; después, en el Target Group, observe initial → healthy.
44. Repitan la Prueba A y verifiquen que el nuevo instance ID ya recibe tráfico.

Secuencia que debe poder explicarse

Evento observable	Responsabilidad
Se termina una instancia del ASG	Fallo inducido / EC2
El target deja de ser elegible para nuevas solicitudes	Health + Target Group
El ALB continúa con targets elegibles	Application Load Balancer
El ASG detecta una instancia no running y queda por debajo de desired	Auto Scaling / EC2 health
El ASG lanza un reemplazo	Recuperación de desired capacity
La nueva instancia se registra y pasa health checks	ASG + Target Group
El ALB vuelve a enviar tráfico al nuevo target	Balanceo
El grupo vuelve a dos instancias	desired=2 recuperado
NO afirmar: “el health check del ALB provocó el reemplazo”. En esta configuración los health checks de ELB no están habilitados como health source del ASG. La instancia fue terminada; Auto Scaling detecta que ya no está running y la reemplaza para mantener desired capacity.	

Validación: Existe evidencia de la instancia terminada, de la actividad de reemplazo, de un nuevo instance ID, del retorno a dos targets healthy y de solicitudes atendidas por el reemplazo.

8. Evidencias y criterios de aceptación

- VPC dcl-dev-vpc y subnets dcl-dev-subnet-a / dcl-dev-subnet-b con sus CIDR heredados de S01.
- ALB dcl-dev-alb en estado Active y endpoint accesible.
- Target Group dcl-dev-tg-web con dos targets healthy antes de la prueba de fallo.
- Prueba de distribución con respuestas de al menos dos instance IDs.
- ASG dcl-dev-asg-web con min=2 / desired=2 / max=4 y sin scaling policy.
- ID de la instancia terminada y evidencia de su cambio de estado.
- Activity history o vista equivalente que muestre el lanzamiento del reemplazo.
- Nuevo instance ID registrado en el Target Group y posteriormente healthy.
- Repetición de la prueba de distribución mostrando recuperación.
- Explicación breve y correcta de qué hace health, qué hace ALB y qué hace ASG.

Respuesta de cierre

Pregunta	Respuesta del equipo
¿Qué hace health?	
¿Qué hace el ALB?	
¿Qué hace el ASG?	
¿Por qué max=4 no implica escalar automáticamente a 4?	

Checkpoint hacia Semana 3

Conserven las evidencias del fallo y de la recuperación, pero restauren la infraestructura al baseline de S01. La siguiente semana cambia la pregunta arquitectónica:

“si una instancia puede desaparecer, el estado que necesitamos conservar no puede depender únicamente de ella”

9. Costos, conservación y cleanup

Recursos con costo durante el lab

Recurso	Por qué puede generar costo	Control del lab
Application Load Balancer	Tiempo aprovisionado + capacidad procesada (LCU)	Crear tarde y eliminar al terminar
EC2 del ASG	Tiempo de cómputo On-Demand	t3.micro; desired=2; cleanup inmediato
EBS root	Almacenamiento mientras existe el volumen	Volumen mínimo; Delete on termination
Public IPv4	Direcciones públicas del ALB y de las instancias	Uso temporal; se liberan al eliminar recursos
Data transfer	Puede aplicar según patrón de tráfico	Solo tráfico mínimo de prueba

No se crea NAT Gateway. Internet Gateway, route table, security groups, Target Group, Launch Template y Auto Scaling no se tratan como una razón para mantener infraestructura: son temporales en esta iteración aunque algunos no tengan un cargo horario independiente.

CONSERVAR COMO BASELINE

- VPC dcl-dev-vpc · 10.20.0.0/16.
- dcl-dev-subnet-a · 10.20.1.0/24 y su Availability Zone.
- dcl-dev-subnet-b · 10.20.2.0/24 y su Availability Zone.
- Naming/tags del proyecto y evidencias/checkpoint del equipo.

ELIMINAR — cleanup obligatorio

45. Escalen dcl-dev-asg-web a min=0 y desired=0; esperen a que las instancias terminen. Verifiquen que no queden instancias del grupo ni volúmenes root huérfanos.
46. Eliminen dcl-dev-asg-web.
47. Eliminen dcl-dev-alb y esperen a que sus interfaces de red se liberen.
48. Eliminen dcl-dev-tg-web.
49. Eliminen dcl-dev-lt-web y sus versiones.
50. Eliminen dcl-dev-sg-app y dcl-dev-sg-alb cuando ya no tengan dependencias.
51. Desasocien dcl-dev-rt-s02-public de ambas subnets; las subnets volverán a usar la main route table de la VPC.
52. Eliminen dcl-dev-rt-s02-public.
53. Desadjunte y eliminen dcl-dev-igw-s02.
54. Verifiquen que solo permanezcan los recursos declarados en CONSERVAR COMO BASELINE.

Validación de cleanup: No existen ALB, ASG, instancias S02, Target Group, Launch Template, security groups S02, route table S02 ni Internet Gateway S02. Permanecen únicamente la VPC, las dos subnets y el checkpoint.

10. Cierre técnico

- Health responde si un target es elegible para atender solicitudes; no es sinónimo de recuperación.
- El ALB distribuye tráfico entre targets elegibles; no mantiene desired capacity.
- El ASG intenta mantener desired capacity y reconstruye cómputo usando el Launch Template.
- max=4 limita el tamaño permitido, pero sin una scaling policy no existe una decisión automática de crecer por demanda.

Fuentes oficiales

- AWS — Create an Application Load Balancer — <https://docs.aws.amazon.com/elasticloadbalancing/latest/application/create-application-load-balancer.html>
- AWS — Health checks for instances in an Auto Scaling group — <https://docs.aws.amazon.com/autoscaling/ec2/userguide/health-checks-overview.html>
- AWS — Prepare to attach an Elastic Load Balancing load balancer — <https://docs.aws.amazon.com/autoscaling/ec2/userguide/getting-started-elastic-load-balancing.html>

- AWS — Manual scaling for Amazon EC2 Auto Scaling — <https://docs.aws.amazon.com/autoscaling/ec2/userguide/ec2-auto-scaling-scaling-manually.html>
- AWS — Elastic Load Balancing pricing — <https://aws.amazon.com/elasticloadbalancing/pricing/>
- AWS — Amazon VPC pricing — <https://aws.amazon.com/vpc/pricing/>